

Análise léxica

Thiago Alexsander¹

¹Universidade Tecnológica Federal Do Paraná (UTFPR)
R. Rosalina Maria Ferreira, 1233 - Vila Carola, Campo Mourão - PR, 87301-899

²DACOM –
Universidade Tecnológica Federal Do Paraná – Campo Mourão, PR – Brazil

thiago.2014@alunos.utfpr.edu.br

Abstract.

Resumo. Este artigo tem como objetivo esclarecer e objetificar o desenvolvimento de uma análise léxica pertencente a um compilador da linguagem T++.

1. Introdução

O primeiro estado de um compilador é percorrer o arquivo alvo, separando os caracteres em marcadores (*tokens*), por meio de expressões regulares cada *token* é identificado em símbolos especiais ou identificadores, este passo é denominado de Análise léxica.

A análise léxica foi desenvolvida utilizando a linguagem Python em conjunto com uma biblioteca específica para o aprendizado de desenvolvimento de compiladores (PLY), essa biblioteca oferece ferramentas para realizar a análise léxica e sintática.

2. T++

A linguagem T++ é uma linguagem que oferece suporte aos tipos básicos de dados, como inteiro, flutuante, notação científica e *arrays*, porém não possui suporte a caracteres de texto, como *strings* e *char*. Outra característica da do T++ é que sua sintaxe é completamente em português, desse modo ajudando falantes da língua portuguesa a ter um primeiro contato com a programação.

3. Palavras reservadas

As palavras reservadas em T++ podem ser vista na Figura 1, a primeira coluna se refere a como a palavra é encontrada no arquivo alvo, já a segunda coluna é como essa palavra reservada é interpretada pela análise léxica.

'se'	''SE''
'então'	'ENTAO'
'senão'	'SENAO'
'até'	'ATE'
'repita'	'REPITA'
'flutuante'	'FLUTUANTE'
'retorna'	'RETORNA'
'leia'	'LEIA'
'escreva'	'ESCREVA'
'inteiro'	'INTEIRO'
'fim'	'FIM'

Figura 1. Palavras reservadas

4. Lista de símbolos

A lista de símbolos é composta por *tokens* que representam alguma aritmética ou atribuição de valores dentro da linguagem.

Tabela 1. Símbolos

+
-
*
/
=
,
:=
<
>
>=
<=
(
)
:
[
]
&&
!

4.1. Funções auxiliares

Para o funcionamento satisfatório da análise léxica utilizou-se de funções para realizar a identificação do *tokens*, ID e símbolos.

A função `t_ID` é a identificadora de ID que usa da expressões regular `[a-zA-ZÀ-ÿ_][a-zA-Z_0-9]*` de forma a identificar se é uma palavra reservada.

A função `t_NOTCIENTIFICA` identifica se um dado número é em forma de notação científica fazendo o uso da expressão regular `([+-]?((d+)(.d+)([eE][+---]?((d+))))`

`t_NUMFLUTUANTE` identifica se o número é de ponto flutuante, usando a seguinte expressão regular `([+-]?d+)((d+)-((d+)))`

`t_NUMINTEIRO` identifica um numero inteiro usando a expressão regular `([+-]?d+)`

`t_newline` para identificar uma nova linha `n+`

5. Figures and Captions

t_error que acusa caso exista um erro em alguma linha do arquivo alvo.

6. Exemplos

Com uma entrada na linguagem T++ como mostra a Figura 2

```
1      inteiro: n
2      inteiro: b
3
4      inteiro fat( flutuante: a, inteiro: b)
5      ... a:= 10.5
6      fim
7
8      inteiro fatorial(inteiro: n)
9      ... inteiro: fat
10     ... se n > 0 então {não calcula se n > 0}
11     ...     fat := 1
12     ...     repita
13     ...         fat := fat * n
14     ...         n := n - 1
15     ...     até n = 0
16     ...     retorna(fat) {retorna o valor do fatorial de n}
17     ... senão
18     ...     retorna(0)
19     ... fim
20     fim
21
22     inteiro principal()
23     ... leia(n)
24     ... escreva(fatorial(n))
25     ... escreva(fat(1,1))
26     fim
```

Figura 2. Exemplo entrada

O resultado da análise léxica ficou como mostra a Figura 3

```

1  Tipo:[INTEIRO] Valor:[inteiro] Linha:[1]
2  Tipo:[DOISPONTOS] Valor[:] Linha:[1]
3  Tipo:[ID] Valor:[n] Linha:[1]
4  Tipo:[INTEIRO] Valor:[inteiro] Linha:[2]
5  Tipo:[DOISPONTOS] Valor[:] Linha:[2]
6  Tipo:[ID] Valor:[b] Linha:[2]
7  Tipo:[INTEIRO] Valor:[inteiro] Linha:[4]
8  Tipo:[ID] Valor:[fat] Linha:[4]
9  Tipo:[APAREN] Valor:[ ( ] Linha:[4]
10 Tipo:[FLUTUANTE] Valor:[flutuante] Linha:[4]
11 Tipo:[DOISPONTOS] Valor[:] Linha:[4]
12 Tipo:[ID] Valor:[a] Linha:[4]
13 Tipo:[VIRGULA] Valor:[,] Linha:[4]
14 Tipo:[INTEIRO] Valor:[inteiro] Linha:[4]
15 Tipo:[DOISPONTOS] Valor[:] Linha:[4]
16 Tipo:[ID] Valor:[b] Linha:[4]
17 Tipo:[FPAREN] Valor:[ ) ] Linha:[4]
18 Tipo:[ID] Valor:[a] Linha:[5]
19 Tipo:[ATRIBUICAO] Valor[:] := ] Linha:[5]
20 Tipo:[NUMFLUTUANTE] Valor:[10.5] Linha:[5]
21 Tipo:[FIM] Valor:[fim] Linha:[6]
22 Tipo:[INTEIRO] Valor:[inteiro] Linha:[8]
23 Tipo:[ID] Valor:[fatorial] Linha:[8]
24 Tipo:[APAREN] Valor:[ ( ] Linha:[8]
25 Tipo:[INTEIRO] Valor:[inteiro] Linha:[8]
26 Tipo:[DOISPONTOS] Valor[:] Linha:[8]
27 Tipo:[ID] Valor:[n] Linha:[8]
28 Tipo:[FPAREN] Valor:[ ) ] Linha:[8]
29 Tipo:[INTEIRO] Valor:[inteiro] Linha:[9]
30 Tipo:[DOISPONTOS] Valor[:] Linha:[9]
31 Tipo:[ID] Valor:[fat] Linha:[9]
32 Tipo:[SE] Valor:[se] Linha:[10]
33 Tipo:[ID] Valor:[n] Linha:[10]
34 Tipo:[MAIOR] Valor:[>] Linha:[10]
35 Tipo:[NUMINTEIRO] Valor:[0] Linha:[10]
36 Tipo:[ENTAO] Valor:[então] Linha:[10]

```

Figura 3. Resultado de uma análise